

Predicción del Riesgo de Cardiopatía Coronaria utilizando Modelos de Aprendizaje Automático

Uriel De la Cruz Saavedra

August 2025

1. Introducción

El presente trabajo tiene como objetivo aplicar la técnica de regresión logística y árbol de decisión para predecir la probabilidad de padecer cardiopatía coronaria, explorando el papel de distintos factores clínicos y demográficos. Con ello, se busca demostrar cómo los modelos matemáticos pueden contribuir a la toma de decisiones médicas y al diseño de estrategias preventivas más efectivas. La regresión logística es un modelo ampliamente utilizado en el ámbito biomédico por su capacidad para estimar la probabilidad de que ocurra un evento binario, como la presencia o ausencia de una enfermedad. A través del análisis de variables como la edad, el colesterol, la presión arterial o los hábitos de vida, este modelo permite construir predicciones basadas en patrones observados en los datos. Este trabajo es elaborado por estudiantes de los Estudios Técnicos Especializados en Computación de parte de la Escuela Nacional Preparatoria Número 4 “Vidal Castañeda y Nájera” en conjunto con la técnica académica Ingrid Midory Monterroso Alfaro, responsable del programa de Prácticas Profesionales y Servicio Social “Data Minds. Laboratorio de Inteligencia Artificial” del mismo plantel.

1.1. Objetivos

Predecir la ausencia o presencia de la enfermedad de cardiopatía coronaria (CC o Coronary Heart Disease, CHD) en un periodo de 10 años, mediante la aplicación de técnicas de aprendizaje automático (Machine Learning). Para ello, se emplearán algoritmos de clasificación, específicamente regresión logística y árbol de decisión, los cuales permiten modelar la probabilidad de ocurrencia de un evento binario. En este caso, ambos modelos clasificarán los resultados en dos categorías —presencia o ausencia de la enfermedad—, lo que los convierte en herramientas adecuadas para comparar su eficiencia y desempeño en la predicción de la cardiopatía coronaria. La base de datos utilizada se encuentra disponible para uso público en *National Heart, Lung, and Blood Institute*.

1.2. Motivación

La cardiopatía coronaria limita la llegada de sangre y oxígeno al corazón, su principal causa es el acumulamiento de placa en las arterias coronarias, haciéndolas más angostas¹. Las cardiopatías son la principal causa de muerte en México desde hace más de veinte años, siendo causantes del 15.7 % de la mortalidad total, a su vez, la cardiopatía coronaria es la causa del 10.1 % de las muertes totales y del 64.1 % de las muertes por cardiopatías¹. La mortalidad de estas enfermedades ha ido en aumento desproporcionado en relación a la población desde el año 1950, y sumando que en México, la diabetes y la obesidad (relacionadas con las cardiopatías) son otro gran problema de salud, nos podemos dar cuenta de la importancia de prevenir y tratar esta enfermedad.

2. Preliminares

2.1. Inteligencia Artificial (IA)

La Inteligencia Artificial (IA) es una rama de la informática que busca desarrollar sistemas capaces de realizar tareas que, tradicionalmente, requieren de la inteligencia humana. Entre estas tareas se incluyen el razonamiento, el aprendizaje, la percepción, la comprensión del lenguaje natural y la toma de decisiones. En términos generales, la IA pretende dotar a las máquinas de la capacidad de aprender de la experiencia, adaptarse a nuevos contextos y resolver problemas de manera autónoma.

2.2. Aprendizaje Automático (Machine Learning)

El Aprendizaje Automático (Machine Learning, ML) es una subdisciplina de la Inteligencia Artificial que se centra en el desarrollo de algoritmos capaces de aprender patrones a partir de los datos, sin necesidad de ser programados explícitamente para cada tarea. Estos algoritmos construyen modelos que permiten hacer predicciones o tomar decisiones basadas en información previa.

Dentro del Machine Learning existen tres tipos principales de aprendizaje:

- **Supervisado:** en el que el modelo se entrena con datos etiquetados para predecir una salida conocida.
- **No supervisado:** que busca descubrir estructuras o patrones ocultos en datos sin etiquetar.
- **Por refuerzo:** en el que un agente aprende mediante la interacción con su entorno, recibiendo recompensas o penalizaciones según sus acciones.

En el presente proyecto se utilizarán modelos de aprendizaje supervisado, ya que se cuenta con un conjunto de datos etiquetados que indican la ausencia o presencia de la enfermedad de cardiopatía coronaria. Estos modelos —Regresión Logística y Árbol de Decisión— pertenecen al ámbito del aprendizaje supervisado y se utilizan para resolver problemas de clasificación binaria, como en este caso, la predicción de la presencia o ausencia de la enfermedad de cardiopatía coronaria. A continuación, se detallan las bases matemáticas de cada uno de los algoritmos que se emplearán en este proyecto.

2.2.1. Regresión Logística

La regresión logística es un modelo estadístico utilizado para predecir la probabilidad de que ocurra un evento binario, es decir, uno que solo puede tomar dos posibles resultados (por ejemplo, presencia o ausencia de una enfermedad). A diferencia de la regresión lineal, que predice valores continuos, la regresión logística transforma la salida mediante una función sigmoidea, también conocida como función logística.

Matemáticamente, el modelo se expresa como:

$$P(y = 1 | X) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n)}} \quad (1)$$

donde:

- $P(y = 1 | X)$ representa la probabilidad de que ocurra el evento, en este caso, la probabilidad de que un paciente padezca cardiopatía coronaria.
- β_0 es el término independiente.
- β_i son los coeficientes del modelo asociados a cada variable
- e es la base de los logaritmos naturales.

La función sigmoidea transforma los valores de entrada en un rango entre 0 y 1, lo que permite interpretar el resultado como una probabilidad. Si la probabilidad obtenida supera un cierto umbral (por ejemplo, 0.5), el modelo clasifica el caso como “presencia de enfermedad”; de lo contrario, como “ausencia de enfermedad”.




Figura 1: Función Sigmoidea

Como podemos ver en la gráfica de la función Sigmoide, cuya ecuación es $\sigma(x) = \frac{1}{1+e^{-x}}$, esta convierte los valores de una función continua en valores entre 0 y uno, de manera que permite hacer una clasificación de la siguiente manera:

- $\sigma(z)$ tiende a 1 como z se acerque a ∞
- $\sigma(z)$ tiende a 0 como z se acerque a $-\infty$
- $\sigma(z)$ siempre está acotado entre 0 y 1

donde la probabilidad de que la variable objetivo se encuentre en cada clase se puede medir como:

- $P(y = 1) = \sigma(z)$
- $P(y = 0) = 1 - \sigma(z)$

El entrenamiento del modelo se realiza ajustando los parámetros mediante la maximización de la verosimilitud, buscando los valores que mejor se ajusten a los datos observados.

2.2.2. Árbol De Decisión

El árbol de decisión es un algoritmo de clasificación que organiza los datos en forma de estructura jerárquica similar a un árbol. En cada nodo interno se evalúa una condición sobre una variable (por ejemplo, “¿El colesterol > 240?”), y según la respuesta (“sí” o “no”), los datos se dividen en ramas hasta llegar a una hoja, que representa una clase final (presencia o ausencia de la enfermedad).

El objetivo del modelo es dividir los datos de manera que cada grupo (rama o nodo) sea lo más homogéneo posible respecto a la variable de salida.

Para decidir la mejor división, el algoritmo utiliza medidas de impureza, entre las que destacan:

- **Índice de Gini:**

$$Gini = 1 - \sum_{i=0}^C p_i^2 \quad (2)$$

donde p_i es la proporción de elementos de la clase i en el nodo. Un valor de Gini cercano a 0 indica que el nodo es puro (pertenece casi por completo a una sola clase).

■ **Entropía (utilizada en algunos modelos):**

$$Entropy = - \sum_{i=0}^C p_i \log_2(p_i) \quad (3)$$

La entropía mide la incertidumbre o desorden del nodo; cuanto menor es su valor, mayor es la pureza del conjunto.

El proceso de construcción del árbol continúa de manera recursiva hasta que los nodos alcanzan una pureza aceptable o se cumple algún criterio de parada (como una profundidad máxima).

Entre sus ventajas, los árboles de decisión son fáciles de interpretar, no requieren normalización de los datos y pueden capturar relaciones no lineales entre las variables. Sin embargo, son sensibles al sobreajuste (overfitting), por lo que se recomienda podar el árbol o combinarlo con otros métodos (como Random Forest o Gradient Boosting) para mejorar su generalización.

La elección de la regresión logística y del árbol de decisión en este proyecto responde al interés de comparar dos enfoques distintos dentro del aprendizaje supervisado. La regresión logística se basa en un modelo estadístico lineal que permite interpretar de manera directa la influencia de cada variable sobre la probabilidad de padecer cardiopatía coronaria. Su fortaleza radica en su simplicidad, interpretabilidad y eficiencia computacional, lo que la convierte en una herramienta sólida para establecer relaciones lineales entre los factores de riesgo y la enfermedad.

Por otro lado, el árbol de decisión ofrece un enfoque no lineal y jerárquico, capaz de capturar interacciones complejas entre las variables sin necesidad de transformaciones previas. Además, su estructura visual facilita la interpretación intuitiva del proceso de decisión, mostrando cómo se combinan las condiciones para llegar a una predicción.

Al emplear ambos algoritmos, se busca no solo evaluar cuál ofrece un mejor desempeño predictivo, sino también comparar su capacidad de interpretación y generalización sobre los datos. Esta comparación permitirá determinar qué modelo resulta más adecuado para la detección temprana de la cardiopatía coronaria en función del equilibrio entre precisión, explicabilidad y eficiencia.

3. Predicción de la Cardiopatía Coronaria

Se usara Google Colab para ejecutar el modelo de regresión logística y árbol de decisión, usando el lenguaje de programación Python. Podrá encontrar el código en los siguientes enlaces: [Heart Disease Prediction Using Logistic Regression](#) y [Heart Disease Prediction Using Decision Tree](#). Los datos sobre el CC o CHD fueron obtenidos de un estudio realizado a los habitantes de la ciudad de Framingham, Massachusetts. Este estudio fue realizado con la finalidad de conocer la causalidad de las enfermedades cardiovasculares en la comunidad de Framingham. Dicho conjunto de datos que utilizaremos para realizar el análisis y construir un modelo de agrupación se encuentra disponible para uso público en *National Heart, Lung, and Blood Institute*.

3.1. Análisis exploratorio de los datos

El análisis exploratorio de datos (EDA) constituye una etapa fundamental en todo proyecto de aprendizaje automático, ya que permite comprender la estructura y las características del conjunto de datos antes de aplicar los modelos predictivos. En esta fase se examinan aspectos como la distribución de las variables, la presencia de valores faltantes o atípicos (outliers), las relaciones entre las variables cuantitativas y cualitativas, y posibles correlaciones con la variable objetivo (TenYearCHD). Este proceso no solo facilita la detección temprana de problemas en los datos, sino que también orienta la selección y el preprocesamiento de las variables, garantizando que los algoritmos de clasificación —regresión logística y árbol de decisión— se apliquen sobre información limpia y relevante.

Los datos comenzaron a recabarse en 1948, e inicialmente se estudiaron a 5,209 sujetos a quienes se les hacía exámenes médicos cada dos años, además, se les daba un seguimiento continuo para obtener resultados sobre su condición cardiovascular. Finalmente el estudio terminó con datos de 4,434 participantes a quienes se les dio seguimiento por 24 años. El estudio contiene más de 4,000 registros y 16 atributos: **male**, **age**, **education**, **currentSmoking**, **cigsPerDay**, **BPMeds**, **prevalentStroke**, **prevalentHyp**, **diabetes**, **totChol**, **sysBP**, **diaBP**, **BMI**, **heartrate**, **glucose** y por último **TenYearCHD**.

Para comprender mejor las características del conjunto de datos utilizado, a continuación, se muestra una tabla descriptiva que resume las variables incluidas en el conjunto de datos. En ella se especifican el nombre de cada variable, su descripción, tipo de dato y naturaleza (cualitativa o cuantitativa).

Variable	Descripción	Tipo de dato	Tipo de variable
male	Sexo (0= mujer, 1= hombre)	Binaria	Cualitativa
age	Edad	Entero	Cuantitativa
education	Nivel educativo (1-4)	Entero	Cualitativa
currentSmoking	Fumador frecuente (0=no, 1=sí)	Binaria	Cualitativa
cigsPerDay	Cigarros por día	Numérica	Cuantitativa
BPMeds	Medicación para la presión (0=no, 1=sí)	Binaria	Cualitativa
prevalentStroke	Derrames cerebrales (0=no, 1=sí)	Binaria	Cualitativa
prevalentHyp	Hipertensión (0=no, 1=sí)	Binaria	Cualitativa
diabetes	Diabetes (0=no, 1=sí)	Binaria	Cualitativa
totChol	Nivel de colesterol	Numérica	Cuantitativa
sysBP	Presión sistólica	Numérica	Cuantitativa
diaBP	Presión diastólica	Numérica	Cuantitativa
BMI	Índice de masa corporal	Numérica	Cuantitativa
heartrate	Frecuencia cardíaca	Numérica	Cuantitativa
glucose	Glucosa	Numérica	Cuantitativa
TenYearCHD	Presencia de enfermedad (0=no, 1=sí)	Binaria	Cualitativa

Tabla 1: Tabla de datos

Las estadísticas descriptivas permiten obtener una visión general de las características de la muestra utilizada en el estudio. En total, se analizaron 4,240 registros con diversas variables clínicas y demográficas.

La edad promedio de los participantes fue de aproximadamente 49.6 años, con un rango entre 32 y 70 años. El 42.9 % correspondió a hombres y cerca del 49 % eran fumadores activos, con un promedio de 9 cigarrillos por día. En cuanto a las condiciones médicas, un 31 % presentaba hipertensión y un 2.6 % diabetes. Los valores promedio de presión sistólica y diastólica fueron de 132 mmHg y 83 mmHg respectivamente, mientras que el colesterol total promedio fue de 236 mg/dl y el índice de masa corporal (BMI) medio de 25.8.

Finalmente, el 15.2 % de los individuos desarrolló enfermedad coronaria en un periodo de diez años, lo que muestra un desequilibrio en la variable objetivo (TenYearCHD) como se logra ver en la figura 2, aspecto relevante para el desempeño de los modelos predictivos.




Figura 2: Distribución de CHD a 10 años

Estas estadísticas ofrecen un panorama inicial del conjunto de datos y sirven como punto de partida para el análisis exploratorio y los modelos predictivos aplicados posteriormente.

Los datos muestran que la edad promedio de los participantes en el estudio es de aproximadamente 49.6 años, con una desviación estándar de 8.6 años, lo que indica una dispersión moderada en torno a la media. La edad mínima registrada es de 32 años y la máxima de 70 años, por lo que el conjunto de datos representa principalmente a una población adulta de mediana edad y adulta mayor.

El rango intercuartílico se extiende de 42 a 56 años, lo que significa que el 50 % central de los individuos se encuentra dentro de ese intervalo. Este comportamiento sugiere una distribución relativamente concentrada alrededor de la media, sin presencia de valores atípicos extremos. Dado que la cardiopatía coronaria suele asociarse con la edad, esta variable probablemente tendrá un peso significativo en la predicción del modelo.




Figura 3: Distribución de la Edad

La distribución de la edad según la presencia de cardiopatía coronaria muestra una diferencia notable entre ambos grupos. Las personas que desarrollan la enfermedad en los siguientes diez años tienden a concentrarse en edades mayores, especialmente a partir de los 50 años, donde la curva correspondiente a los casos positivos presenta un incremento más marcado. En contraste, la población sin enfermedad muestra una distribución más uniforme y con menor densidad en los rangos altos de edad. Estos resultados sugieren que la edad es un factor de riesgo relevante para la cardiopatía coronaria, lo cual coincide con la evidencia clínica. La superposición de ambas distribuciones confirma que, aunque existe variabilidad entre individuos, el riesgo aumenta conforme avanza la edad, aportando información valiosa para el entrenamiento de los modelos predictivos.




Figura 4: Distribución de edad según la presencia de Cardiopatía Coronaria




Figura 5: Proporción de Cardiopatía Coronaria por Sexo

La gráfica de la figura 5 muestra la proporción de personas que presentan cardiopatía coronaria (CHD) según el sexo. Se observa que el porcentaje de hombres con diagnóstico de CHD a 10 años es notablemente mayor que el de mujeres. Esto sugiere que el sexo masculino constituye un factor asociado a un mayor riesgo de desarrollar enfermedad coronaria en este conjunto de datos. Esta diferencia coincide con lo repor-

tado en la literatura médica, donde los hombres suelen presentar una mayor prevalencia de enfermedades cardiovasculares, posiblemente debido a factores hormonales, conductuales y metabólicos.

Después de analizar las variables demográficas, como la edad y el sexo, se exploraron algunos factores fisiológicos asociados al riesgo cardiovascular, tales como el colesterol total (totChol), la presión arterial sistólica (sysBP) y su relación con la edad. Estas variables permiten observar con mayor detalle las condiciones de salud que podrían incidir en la aparición de la cardiopatía coronaria (CHD). En la siguiente gráfica relacionamos los niveles de colesterol (totChol), la presión sistólica (sysBP) y la edad (age), donde el eje 'y' es la presión sistólica, el eje 'x' los niveles de colesterol y la gradiente de colores la edad. Al analizar la gráfica concluimos que, de las personas de 45 años o menores la mayoría se encuentran en un conjunto en el que la presión sistólica es menor a 150 y el colesterol es menor a 250 aproximadamente.




Figura 6: sysBp vs totChol vs age

Con el fin de identificar posibles relaciones entre las variables cuantitativas del conjunto de datos, se construyó una matriz de correlación. Esta herramienta permite observar qué tan fuertemente se asocian las variables entre sí, facilitando la detección de factores que podrían influir en la presencia de cardiopatía coronaria.

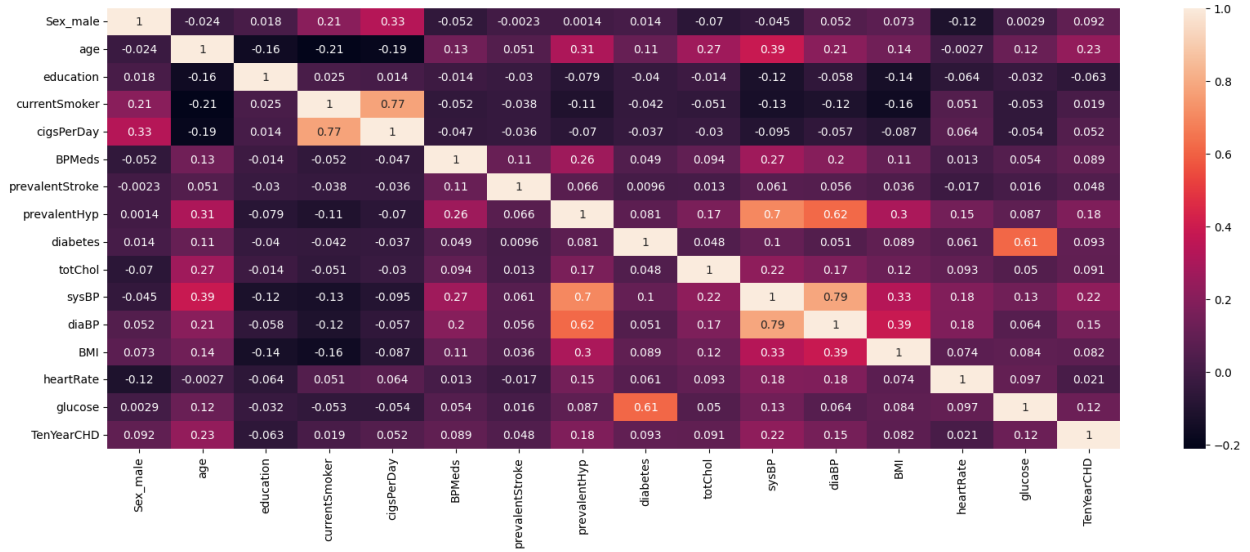


Figura 7: Matriz de correlación

La matriz de correlación permite visualizar la intensidad y dirección de las relaciones entre las variables cuantitativas del conjunto de datos. Se observa que algunas variables presentan correlaciones moderadas entre sí, como la presión sistólica (**sysBP**) y la presión diastólica (**diaBP**), o la edad y la presión arterial, lo cual resulta coherente desde un punto de vista clínico. Por otro lado, variables como el colesterol total (**totChol**) y la glucosa muestran correlaciones más débiles con las demás características. En general, la variable objetivo (**TenYearCHD**) presenta correlaciones bajas con las variables independientes, lo que sugiere que la predicción de la enfermedad requerirá un modelo de clasificación que combine múltiples factores en lugar de depender de una sola variable.

3.2. Regresión Logística

Una vez realizado el análisis exploratorio y la identificación de las variables más relevantes, se procedió a la construcción del modelo de Regresión Logística, cuyo objetivo es predecir la probabilidad de desarrollar cardiopatía coronaria a 10 años.

Comenzamos importando las librerías necesarias, **numpy** que sirve para crear vectores y matrices grandes multidimensionales, y funciones de alto nivel, **scipy.optimize** para optimización, álgebra lineal, integración, interpolación, funciones especiales, FFT, procesamiento de señales y de imagen, resolución de ODEs, etc, **statsmodel.api**, una biblioteca de análisis y modelado de datos estadísticos, y **sklearn** que incluye varios algoritmos de clasificación, regresión y análisis de grupos entre los cuales están máquinas de vectores de soporte, bosques aleatorios, Gradient boosting, K-means y DBSCAN.

```
[ ] import pandas as pd
import pylab as pl
import numpy as np
import scipy.optimize as opt
import statsmodels.api as sm
from sklearn import preprocessing
'exec(% matplotlib inline)'
import matplotlib.pyplot as plt
import matplotlib.mlab as mlab
import seaborn as sns
```

Figura 8: librerías usadas

Luego, se definieron como variables independientes aquellas que mostraron una relación significativa con la enfermedad, tales como la *edad*, el *sexo*, la *frecuencia cardíaca*, el *colesterol total*, la *presión arterial sistólica* y la *glucosa*. La variable dependiente corresponde a la presencia o ausencia de la enfermedad (**TenYearCHD**). Antes del entrenamiento, las variables independientes fueron normalizadas mediante la técnica StandardScaler, con el fin de garantizar que todas las características tuvieran una escala comparable. Posteriormente, los datos se dividieron en un conjunto de entrenamiento (70 %) y otro de prueba (30 %) para evaluar el desempeño del modelo, como se muestra en la siguiente imagen.

```
X = np.asarray(disease_df[['age', 'Sex_male', 'heartRate',
                           'totChol', 'sysBP', 'glucose']])
y = np.asarray(disease_df['TenYearCHD'])

# normalization of the dataset
X = preprocessing.StandardScaler().fit(X).transform(X)

# Train-and-Test -Split
from sklearn.model_selection import train_test_split
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size = 0.3, random_state = 4)

print ('Train set:', X_train.shape, y_train.shape)
print ('Test set:', X_test.shape, y_test.shape)
```

Figura 9: Definición de variables

3.2.1. Resultados Del Modelo De Regresión Logística

El modelo de Regresión Logística se entrenó con las variables previamente seleccionadas, aprendiendo los coeficientes que mejor separan los casos positivos y negativos de cardiopatía coronaria. Una vez entrenado, se realizaron predicciones sobre el conjunto de prueba. La matriz de confusión permite visualizar los aciertos y errores del modelo, distinguiendo los verdaderos positivos (casos correctamente clasificados como con enfermedad) y los falsos positivos o negativos. El reporte de clasificación muestra métricas como la precisión, la recuperación (*recall*) y la *F1-score*, que permiten evaluar la calidad del modelo desde distintas perspectivas. Finalmente, la exactitud (accuracy) global indica el porcentaje de predicciones correctas sobre el total de casos.

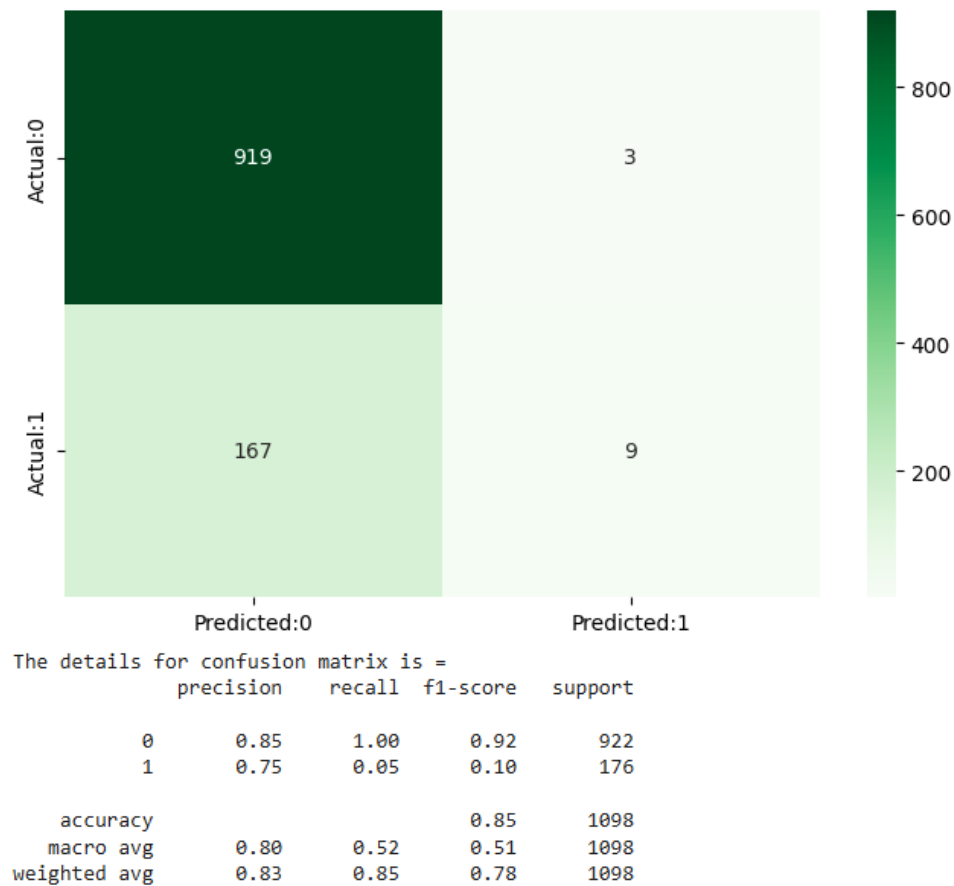


Figura 10: Matriz de confusión y métricas

Los resultados del modelo de Regresión Logística muestran un desempeño general aceptable, con una exactitud (accuracy) del 85 %, lo que indica que el modelo clasifica correctamente la mayoría de los casos. Sin embargo, al analizar las métricas por clase, se observa un desbalance en el rendimiento. Para la clase 0 (sin enfermedad), el modelo presenta un excelente comportamiento, con una precisión de 0.85 y un recall perfecto de 1.00, lo que significa que identifica correctamente todos los casos negativos sin dejar escapar ninguno. En contraste, para la clase 1 (con riesgo de cardiopatía coronaria), el desempeño es mucho menor: la precisión alcanza 0.75, pero el recall es apenas 0.05, lo que evidencia que el modelo tiene dificultades para detectar los casos positivos. Esta diferencia se debe al desequilibrio en el número de muestras por clase, donde los casos sin enfermedad son considerablemente más numerosos. Por ello, aunque el valor global de exactitud parece alto, no refleja adecuadamente la capacidad del modelo para identificar personas con riesgo de CHD, aspecto que será necesario mejorar en etapas posteriores mediante técnicas de balanceo de clases o el uso de otros algoritmos de clasificación.

Dado que el modelo de Regresión Logística mostró un desempeño limitado en la detección de los casos positivos de cardiopatía coronaria —principalmente debido al desequilibrio de clases y a la naturaleza lineal del modelo—, se decidió probar un árbol de decisión como segundo enfoque de clasificación. Este tipo de algoritmo tiene la ventaja de capturar relaciones no lineales entre las variables y manejar mejor interacciones complejas entre los atributos. Además, permite interpretar visualmente el proceso de toma de decisiones mediante su estructura jerárquica, lo que facilita comprender qué factores influyen más en la predicción del riesgo de enfermedad coronaria.

3.3. Árbol De Decisión

Antes de entrenar el modelo de árbol de decisión, fue necesario preparar nuevamente los datos. En primer lugar, se definió la variable dependiente (**TenYearCHD**), que representa la presencia o ausencia de cardiopatía coronaria, y se eliminaron estas etiquetas del conjunto de variables independientes (**X**). Posteriormente, se codificaron las variables categóricas —como el sexo— mediante valores numéricos, de manera que pudieran ser interpretadas por el modelo. Finalmente, se aplicó un proceso de imputación para manejar los valores faltantes, sustituyendo los registros vacíos por el valor anterior disponible (forward fill), con el objetivo de mantener la coherencia y la completitud del conjunto de datos antes del entrenamiento.

```
from sklearn.model_selection import train_test_split
X = disease_df.drop('TenYearCHD', axis = 1)
y = disease_df['TenYearCHD']

#X = X.drop(['Sex_male', 'diabetes', 'totChol', 'sysBP'], axis = 1)

# Codificar variables categóricas (si las hay)
X = X.replace(['male', 'female'], [2, 3])

# Manejar valores faltantes
X.fillna(method = 'ffill', inplace = True)

x_train,x_test,y_train,y_test = train_test_split(X,y, random_state = 0 , train_size = 0.70)
```

Figura 11: Definición de variables para el árbol de decisión

Como podemos ver en la imagen 11, para el modelo de árbol de decisión, se definieron las variables independientes (**X**) y la variable dependiente (**y**). En este caso, **X** está conformada por todas las características del conjunto de datos, excepto la variable objetivo, mientras que **y** corresponde a la variable **TenYearCHD**, que indica la presencia o ausencia de cardiopatía coronaria. Esta separación permite que el modelo aprenda patrones a partir de las variables predictoras y posteriormente pueda estimar la probabilidad de que un individuo desarrolle la enfermedad. De este modo, el árbol de decisión utilizará todos los atributos disponibles para construir reglas jerárquicas que dividan los datos en función de los valores que mejor separen las clases. De igual manera, los datos se dividieron en un conjunto de entrenamiento (70 %) y otro de prueba (30 %) para evaluar el desempeño del modelo.

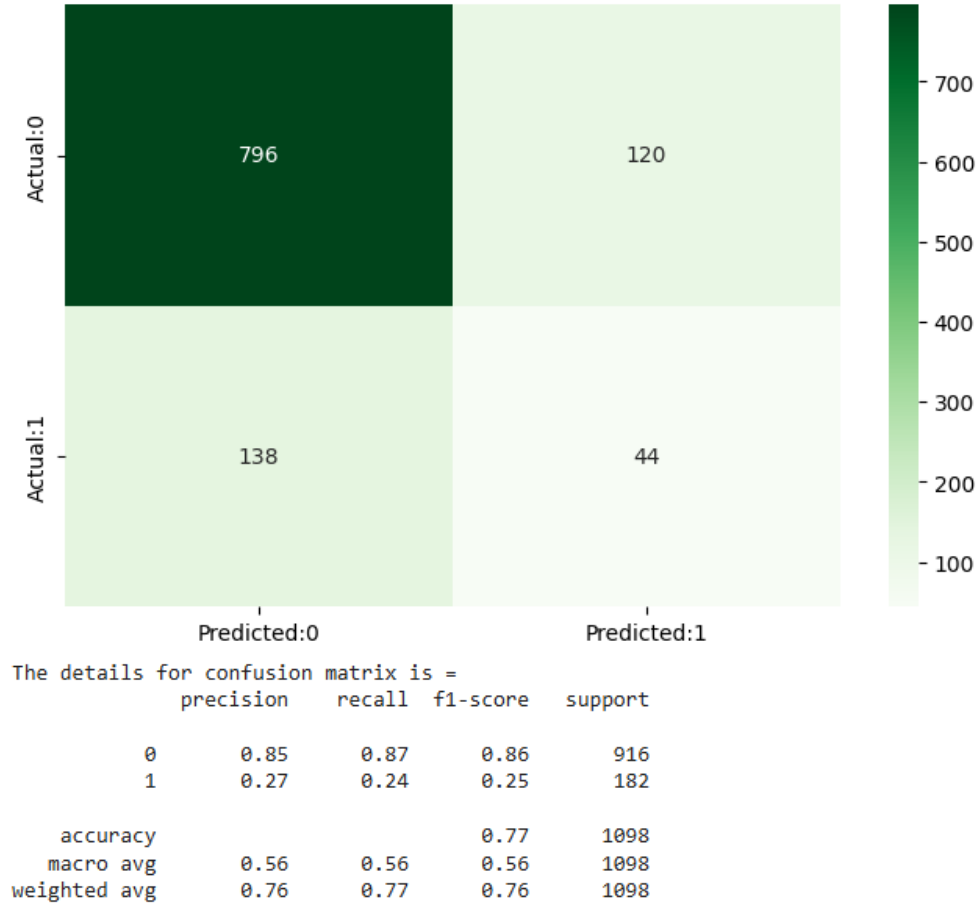


Figura 13: Matriz de confusión y métricas del modelo de árbol de decisión

El modelo de árbol de decisión alcanzó una exactitud (accuracy) del 77 %, lo que representa una ligera disminución respecto a la regresión logística, aunque con un mejor equilibrio en la detección de ambas clases. Para la clase 0 (sin enfermedad), el modelo mantiene un desempeño sólido, con precisión y recall de 0.85 y 0.87, respectivamente. En contraste, para la clase 1 (con riesgo de cardiopatía coronaria), las métricas mejoran levemente en comparación con la regresión logística: la precisión es de 0.27 y el recall de 0.24, lo que indica que el árbol logra identificar un número mayor de casos positivos, aunque todavía de forma limitada. La matriz de confusión muestra que el modelo clasifica correctamente 796 casos sin enfermedad y 44 con enfermedad, pero aún confunde una cantidad considerable de positivos y negativos.

En general, el árbol de decisión captura mejor la complejidad no lineal de los datos, aunque su rendimiento sigue condicionado por el desequilibrio en el número de muestras por clase, aspecto que podría optimizarse mediante técnicas de resampling o ajustes de hiperparámetros.

4. Conclusiones

En este análisis se aplicaron dos métodos de clasificación: Regresión Logística y Árbol de Decisión, con el objetivo de predecir la variable objetivo a partir del conjunto de datos disponible.

La Regresión Logística mostró un desempeño equilibrado al distinguir entre las clases, aunque su precisión se vio limitada por el desbalance en los datos, lo que afectó la capacidad del modelo para identificar correctamente los casos de la clase minoritaria. No obstante, su interpretación resulta sencilla, ya que permite

analizar la relación entre las variables independientes y la probabilidad de pertenecer a una determinada clase.

Por otro lado, el Árbol de Decisión ofreció resultados similares en términos de exactitud global, pero con una ligera mejora en la identificación de algunos casos de la clase minoritaria. Este modelo destaca por su capacidad de representar de forma visual y comprensible (figura 12) el proceso de toma de decisiones, facilitando la interpretación de las reglas generadas. Sin embargo, también puede ser más sensible al ruido o a los datos desbalanceados.

En conjunto, ambos modelos permitieron comprender mejor los patrones presentes en los datos y mostraron que el desempeño puede variar dependiendo del método utilizado y del equilibrio entre las clases. Para mejorar los resultados, sería recomendable aplicar técnicas de balanceo de clases y ajustar los hiperparámetros de los modelos.

Para continuar con este análisis y mejorar la capacidad predictiva de los modelos, se sugieren las siguientes acciones:

- Balancear la base de datos, utilizando técnicas como *oversampling* (por ejemplo, *SMOTE*) o *undersampling*, con el fin de corregir el desbalance entre las clases y permitir que el modelo aprenda de manera más equitativa.
- Ajustar los hiperparámetros de los modelos mediante estrategias como la búsqueda en malla (*Grid Search*) o la búsqueda aleatoria (*Random Search*), para optimizar su rendimiento.
- Probar otros algoritmos de clasificación, como *Random Forest*, *Gradient Boosting* o *Support Vector Machines* (SVM), que podrían ofrecer un mejor desempeño en este tipo de problemas.
- Evaluar nuevas métricas, además de la exactitud, como la AUC-ROC o el F1-score, que brindan una visión más completa en contextos con clases desbalanceadas.
- Analizar la importancia de las variables en ambos modelos para identificar cuáles tienen mayor peso en la predicción y, a partir de ello, proponer estrategias de prevención o intervención en el contexto del estudio.

5. Referencias

1. ¿Qué es el subajuste?(2023, noviembre 7).Ibm.com. <https://www.ibm.com/mx-es/topics/underfitting>.
2. Chávez D. R., R. H., C. G.(2003, Junio). La cardiopatía coronaria en México y su importancia clínica, epidemiológica y preventiva. SciELO. https://www.scielo.org.mx/scielo.php?script=sci_arttext&pid=S1405-99402003000200003.
3. Ibm. (2024, October 10). Árbol de decisión. IBM. <https://www.ibm.com/mx-es/topics/decision-trees#:~:text=Un%C3%A1rbol%20de%20decisi%C3%B3n%20es,internos%20y%20nodos%20de%20hoja>.